Étude de données de santé

Étude des données de santé d'un groupe de patients et en patriculier de leur taux de bilirubine en fonction de différentes variables, et en particulier leur traitrement à la D-peniciline ou la prise du traitement placebo.

```
libname cc "/home/u64044029/CC_STA104";

proc import datafile="/home/u64044029/CC_STA104/inclusion.c
sv"
out=cc.inclusion
DBMS=csv
REPLACE; *ou DBMS=XLS;
GETNAMES=YES;
run;

proc import datafile="/home/u64044029/CC_STA104/suivi.csv"
out=cc.suivi
DBMS=csv
REPLACE; *ou DBMS=XLS;
GETNAMES=YES;
run;
```

```
data cc.inclusion;
set cc.inclusion;
format ddn ddmmyy10.;
ddn=mdy(mois,jour,an);
age1994= 1994 - year(ddn);
run;
```

La date de naissance est stockée dans la variable ddn. L'âge des patients au 1er janvier 1994 est stocké dans la variable age1994.

```
data cc.inclusion;
set cc.inclusion;
poids = poids/2.20462;
```

```
run;

data cc.inclusion;
set cc.inclusion;
if taille > 0 then imc = poids/ ((taille/100)**2);
else imc = .;
run;
```

Le poids en kg est dans la même variable que précédemment. L'IMC est stocké dans la variable IMC

Description rapide de l'IMC

```
proc means data=cc.inclusion n mean std min max;
var imc;
run;
```

La procédure MEANS

Variable d'analyse : imc				
N	Moyenne	Ec-type	Minimum	Maximum
113	24.5607466	2.3149177	19.6326721	30.4617956

Pour les 113 personnes de la table d'inclusion, l'IMC moyen est de 24.6, avec un écart-type de 2.3, un minimum de 19.6 et un maximum de 30.5

Trier les données

```
proc sort data = cc.suivi;
by id vis;
run;
```

Transposer la table

```
proc transpose data = cc.suivi out = cc.bilirubine_transpos
ed prefix = Bilirubine_Vis;
by id;
```

```
id vis;
var bilir;
run;
```

Une donnée par patient avec la bilirubine à chaque visite. Stockée dans la table bilirubine_transposed.

```
data cc.bilirubine_transposed;
set cc.bilirubine_transposed;
drop name;
run;
```

Fusionner les deux tables

```
proc sort data=cc.suivi;   *trier la première;
by id;
run;

proc sort data=cc.inclusion; *trier la seconde;
by id;
run;

data cc.q4;
merge cc.suivi cc.inclusion;  *fusionner les deux : table q
4;
by id;
run;
```

Ne garder que les variables qui nous intéressent : table q4_0

```
data cc.q4_0;
set cc.q4_0;
drop sexe jour mois an poids taille plaquettes age1994 ddn
imc;
run;
```

Différence d'albumine depuis la dernière mesure. Nulle si première mesure

```
proc sort data=cc.q4_0; *trier par patient et visite;
by id vis;
run;
```

Avec toutes les variables

```
data cc.q4_1;
set cc.q4;
by id vis;
diff_albu=albumine-lag(albumine);      *nouvelle albumine-a
ncienne;
if first.num_pat=1 then diff_albu=.;   *nulle si nouveau pa
tient;
run;
```

Avec uniquement les variables demandées

```
data cc.q4_2;
set cc.q4_1;
keep id groupe_ttt vis albumine diff_albu ; *garder les var
iables d'intérêt;
run;
```

Taux de variation de la bilirubine

```
proc sort data=cc.q4_1;
by id vis;
run;
```

```
data cc.q5;
set cc.q4_1;
by id vis;
tauxvar_bilir=(bilir-lag(bilir))/bilir;
if first.num_pat=1 or bilir = 0 then tauxvar_bilir=.;
run;
```

Distribution de la variable

```
proc univariate data=cc.q5;
var tauxvar_bilir;
histogram tauxvar_bilir/ normal;  *affichage de l'histogram
me avec une courbe normale;
inset mean std / format=6.2 position=ne; *ajouter la moyenn
e et l'écart-type;
run;
```

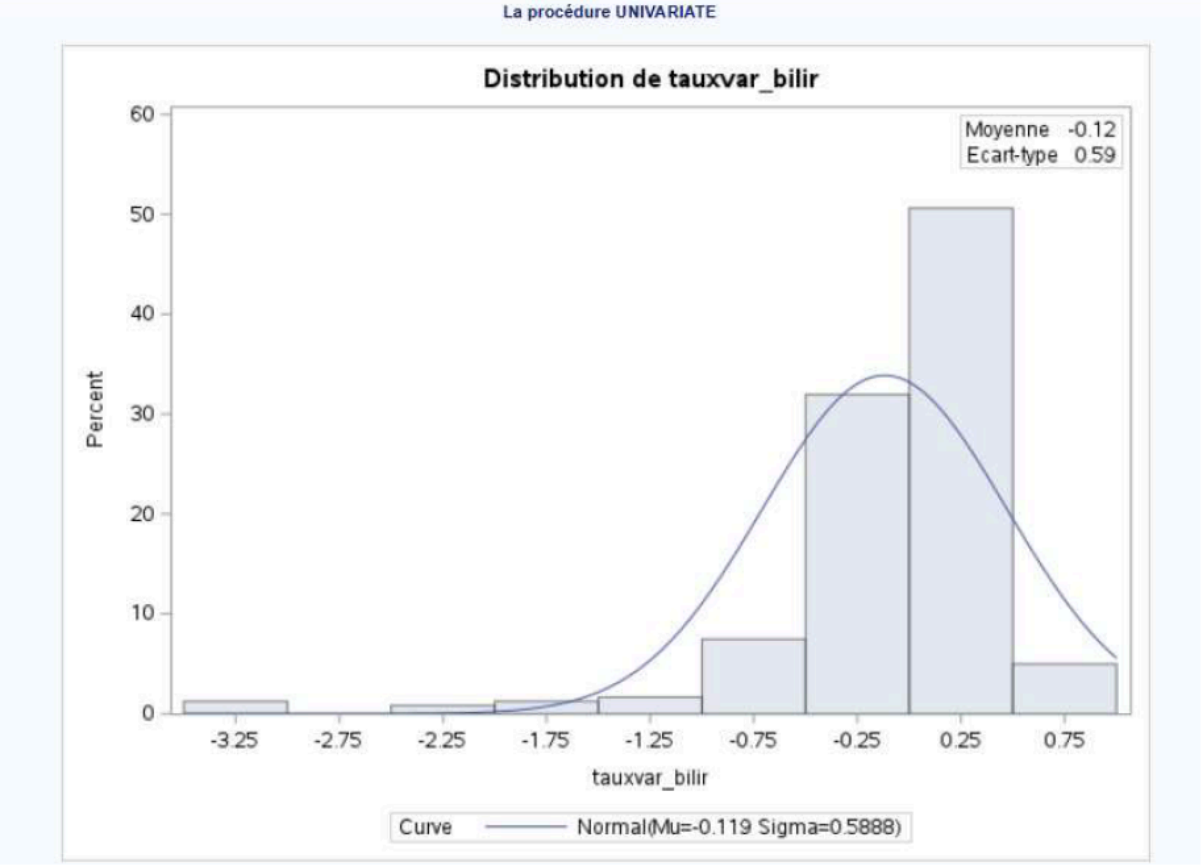

On veut distinguer les variations de bilirubine en quatre catégories : forte décroissance, décroissance, croissance et forte croissance. Pour cela, on regarde les quantiles théoriques de la loi normale de laquelle se rapproche la distribution des taux de variation de bilirubine. Les quantiles sélectionnés sont les quantiles d'ordre 0.25, 0.50 et 0.75. D'après la sortie SAS, leurs valeurs sont respectivement de -0.08846, -0.00770 et 0.07306 . On code donc la variable catégorielle comme suit:

```
proc sort data=cc.q4; *trier par patient et visite;
by id vis;
```

```
run;

data cc.q5;
set cc.q4;
by id vis;
```

Déclaration de la variable caractère

```
length tauxvar_bilir_cat $20; *variable pour les catégorie
s;
```

Calcul du taux de variation

```
tauxvar_bilir = (bilir - lag(bilir)) / bilir;
```

Gestion des valeurs manquantes ou des divisions par zéro

```
if first.id or bilir = 0 then tauxvar_bilir = .;
```

Catégorisation

```
if tauxvar_bilir = . then tauxvar_bilir_cat = ""; *chaîne v
ide pour les valeurs manquantes;
else if tauxvar_bilir < -0.08846 then tauxvar_bilir_cat =
"forte décroissance";
else if tauxvar_bilir >= -0.08846 and tauxvar_bilir < -0.00
770 then tauxvar_bilir_cat = "décroissance";
else if tauxvar_bilir >= -0.00770 and tauxvar_bilir <= 0.07
306 then tauxvar_bilir_cat = "croissance";
else if tauxvar_bilir > 0.07306 then tauxvar_bilir_cat = "f
orte croissance";

run;
```

Ici il était demandé 4 classes alors le choix a été fait de considérer le 0 comme une croissance nulle, et donc de lui assigner la catégorie "croissance". Le choix aurait pu être fait d'ajouter une classe "croissance nulle" qui permet de prendre en compte une absence de variation.

Test avec la bilirubine quantitative : t-test pour comparaison de moyennes de taux de changement de bilirubine

```
proc ttest data=cc.q5;
class Groupe_ttt; *comparaison entre groupe traitement et p
lacebo ;
var tauxvar_bilir; *variable quantitative : taux de changem
ent de bilirubine;
run;
```

Méthode	Variances	DDL	Valeur du test t	Pr > |t|
Pooled	Egal	239	-0.30	0.7654
Satterthwaite	Non égal	224.07	-0.30	0.7668

Egalité des variances				
Méthode	DDL num.	DDL den.	Valeur F	Pr > F
Folded F	116	123	1.50	0.0263

P-valeur non significative au seuil de 5% (p-valeur de 0.7668): pas de différence entre les groupes
(Cas particulier de la non égalité des variances : test d'égalité qui rejette H0, p-valeur de 0.0263)

Illustration avec des boxplots

```
proc sgplot data=cc.q5;
vbox tauxvar_bilir / category=Groupe_ttt; *boxplot de la va
riable quantitative par groupe;
title "Comparaison du changement de bilirubine entre traite
ment et placebo";
run;
```

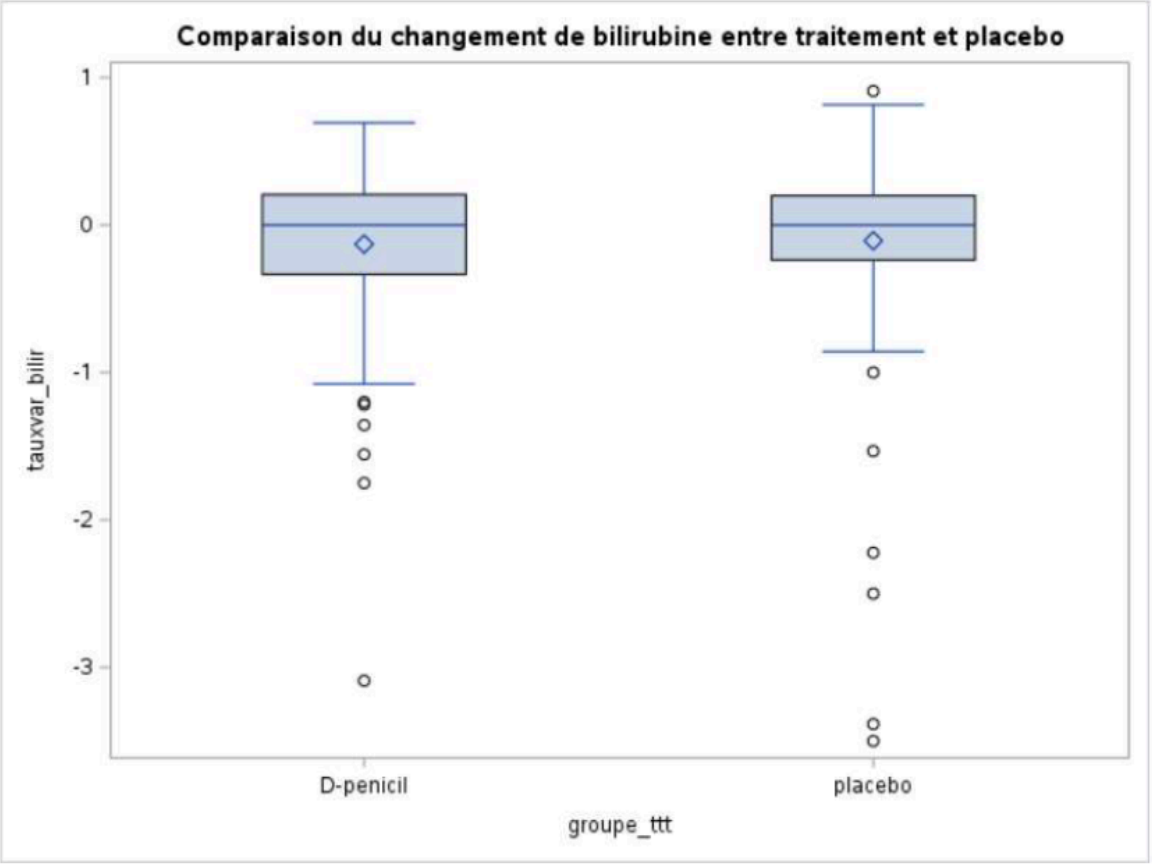

On remarque assez peu de différences entre les deux

Test du chi-deux avec la bilirubine qualitative :

```
proc freq data=cc.q5;
tables Groupe_ttt*tauxvar_bilir_cat / chisq; *Comparaison d
es proportions des catégories entre les groupes;
run;
```

Attention : beaucoup d'effectifs théoriques inférieurs à 5 et beaucoup de données manquantes !

Diagrammes en barres des effectifs pour visualisation

```
proc freq data=cc.q5;
tables Groupe_ttt*tauxvar_bilir_cat / out=freq_data; *Sorti
e des fréquences dans un nouveau dataset;
run;

proc sgplot data=freq_data;
```

```
vbar Groupe_ttt / response=COUNT group=tauxvar_bilir_cat gr
oupdisplay=stack;
title "Répartition des catégories de changement de bilirubi
ne par groupe (empilé)";
run;
```

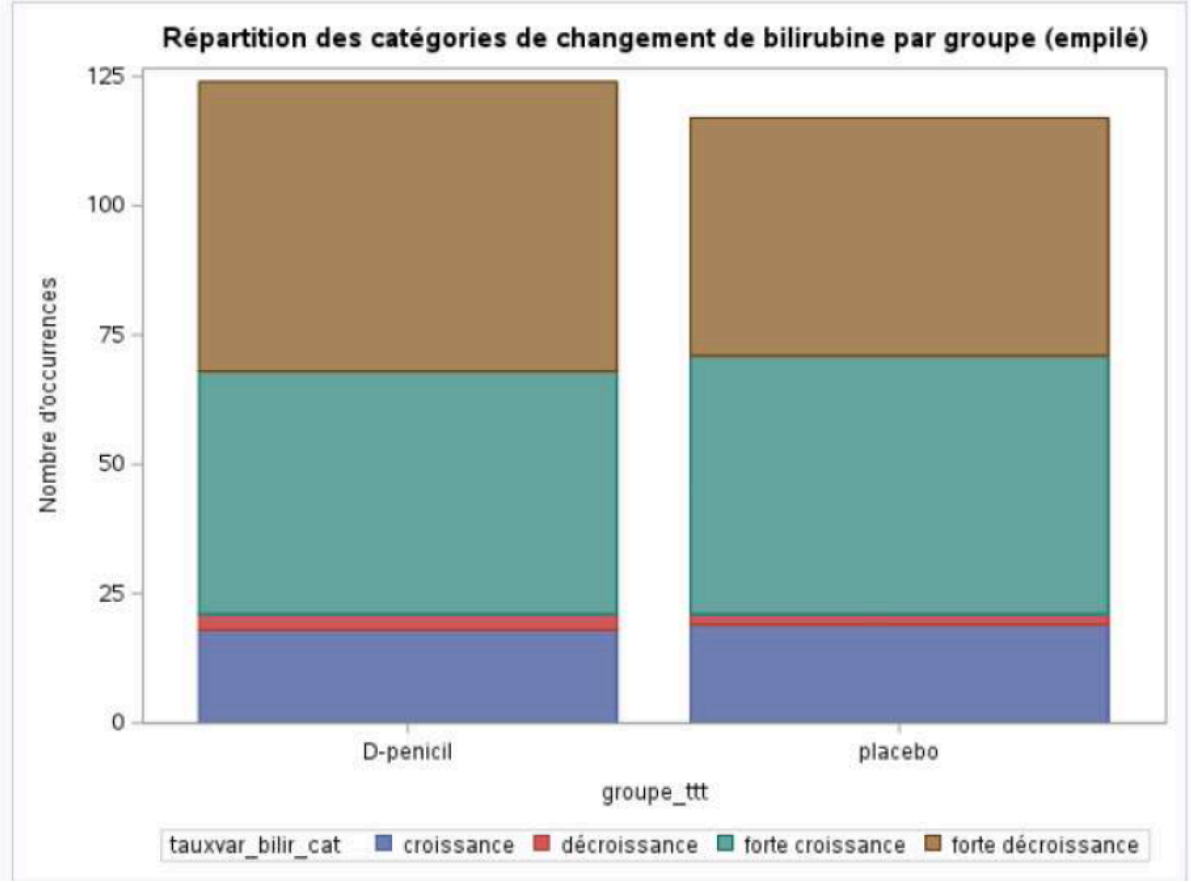

Visualisation de la normalité de l'âge

```
proc univariate data=cc.inclusion;
var age1994;
histogram age1994/ normal;  *affichage de l'histogramme ave
c une courbe normale;
inset mean std / format=6.2 position=ne; *ajouter la moyenn
e et l'écart-type;
run;
```

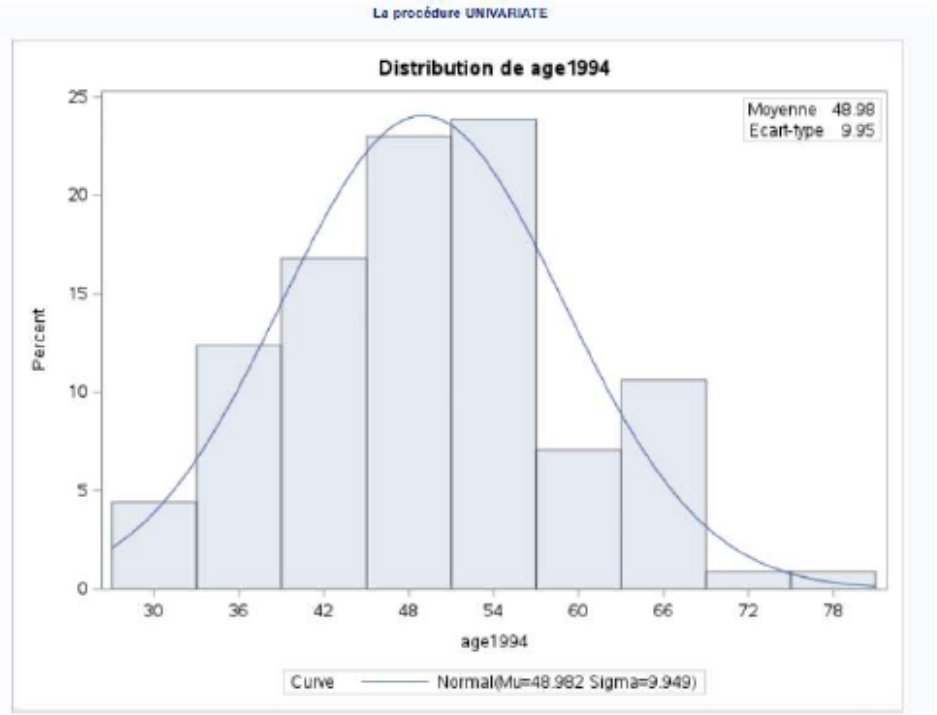

Mais cela ne permet pas de savoir si on peut faire le t-test :
Normalité par sexe

```
proc sgpanel data=cc.inclusion;
panelby Sexe / columns=2;  * Séparer les graphes par sexe,
avec 2 colonnes ;
histogram age1994 / transparency=0.5;  * Histogramme de l'â
ge ;
density age1994 / type=normal;         * Superposition de l
a courbe normale ;
colaxis label="Âge en 1994";
rowaxis label="Fréquence";
title "Distribution de l'âge en 1994 par sexe";
run;
```

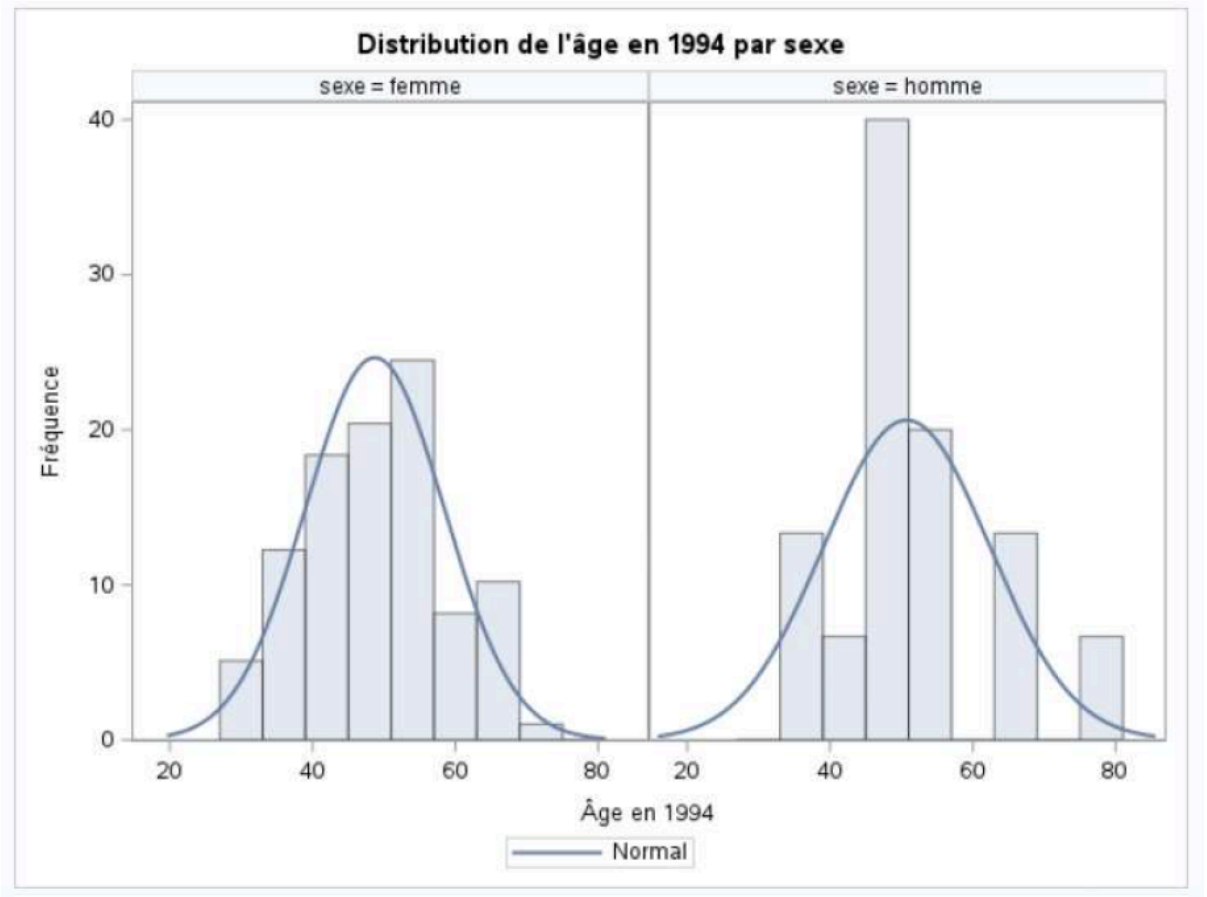
Distribution de l'âge en 1994 par sexe
sexe = femme
sexe = homme
Fréquence
0
10
20
30
40
20
40
60
80
Âge en 1994
Normal

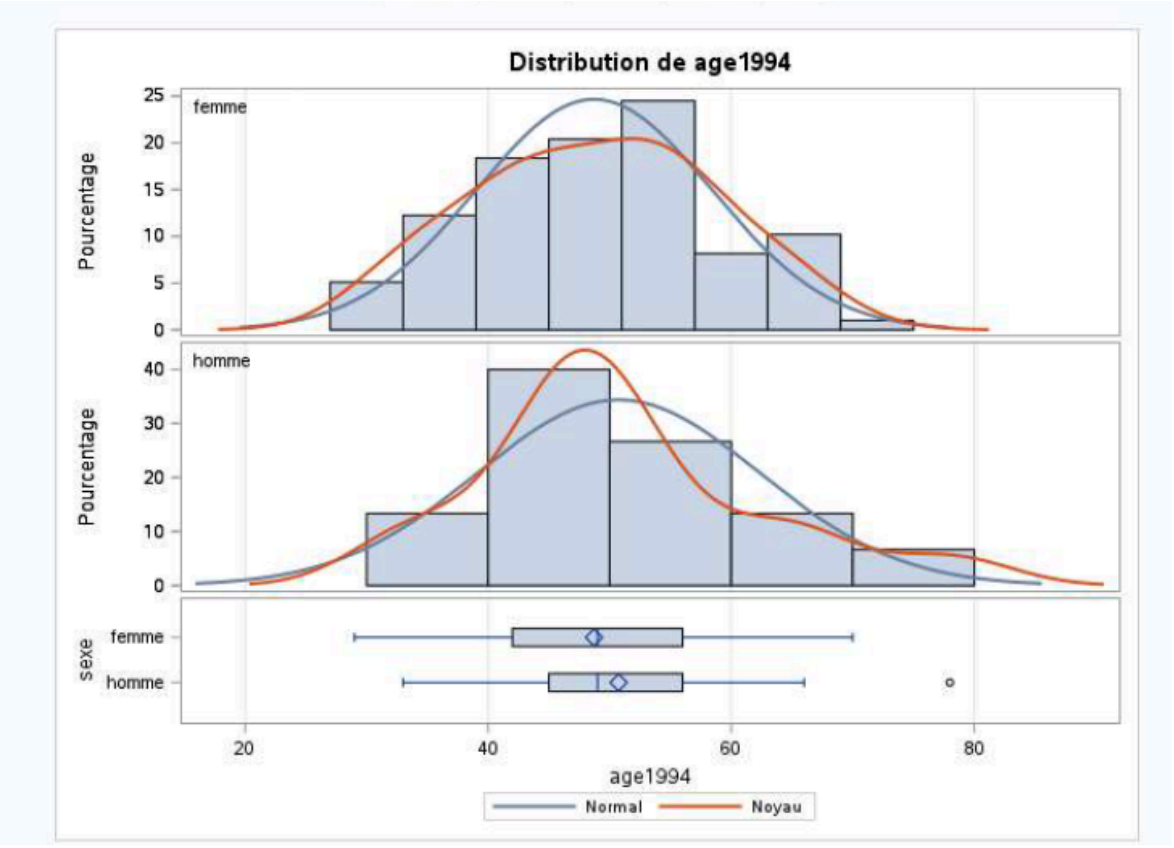
Distribution de age1994
femme
homme
Pourcentage
sexe
age1994
Normal
Noyau

L'âge peut être considéré comme normal dans les deux groupes, on réalise donc un t-test :

```
proc ttest data=cc.inclusion;
class Sexe;  * Variable qui indique le sexe (ex. : 'M' pour
masculin, 'F' pour féminin) ;
var age1994;     * Variable quantitative (l'âge) à comparer
entre les sexes ;
run;
```

Méthode	Variances	DDL	Valeur du test t	Pr > |t|
Pooled	Egal	111	-0.73	0.4667
Satterthwaite	Non égal	17.13	-0.64	0.5305

Egalité des variances				
Méthode	DDL num.	DDL den.	Valeur F	Pr > F
Folded F	14	97	1.43	0.3085

Les QQ-plots montrent bien que les âges suivent une loi normale pour chaque sexe, mais
surtout chez les femmes.
On ne rejette ni l'égalité des variances (p-val 0.3085) ni l'égalité des moyennes d'âge selon le sexe (p-val 0.4667)

Illustration de la différence d'âge avec un boxplot :

```
proc sgplot data=cc.inclusion;
vbox age1994 / category=Sexe;  * Boxplot de l'âge par sexe
;
title "Différence d'âge entre les hommes et les femmes";
run;
```

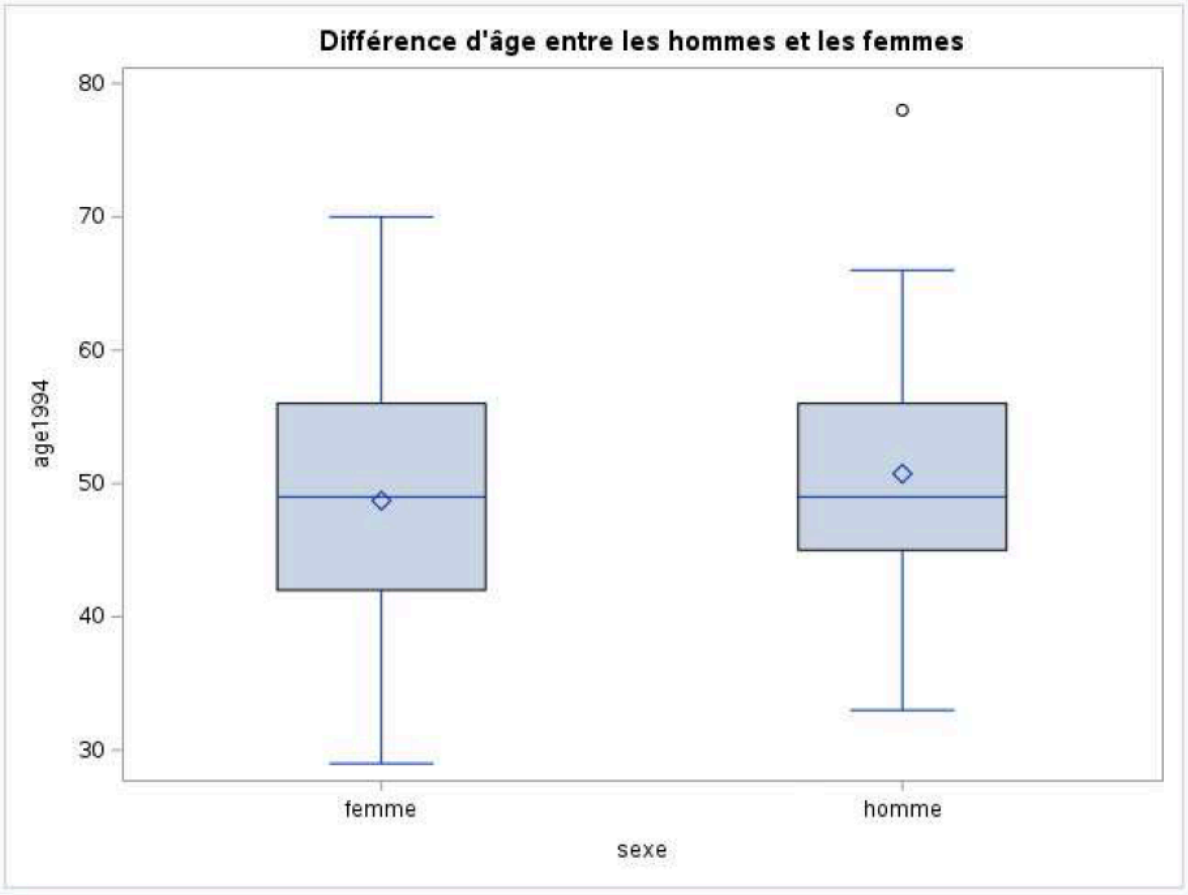

On retrouve visuellement assez peu de différences, ce que traduit bien le résultat du test.

Courbes pour tous les patients

```
proc sgplot data=cc.q5;
series x=Vis y=Bilir / group=id lineattrs=(thickness=2); *
Tracer une ligne par patient ;
xaxis label="Numéro de visite";
yaxis label="Niveau de bilirubine";
title "Évolution de la bilirubine pour un échantillon de 10
patients";
run;
```

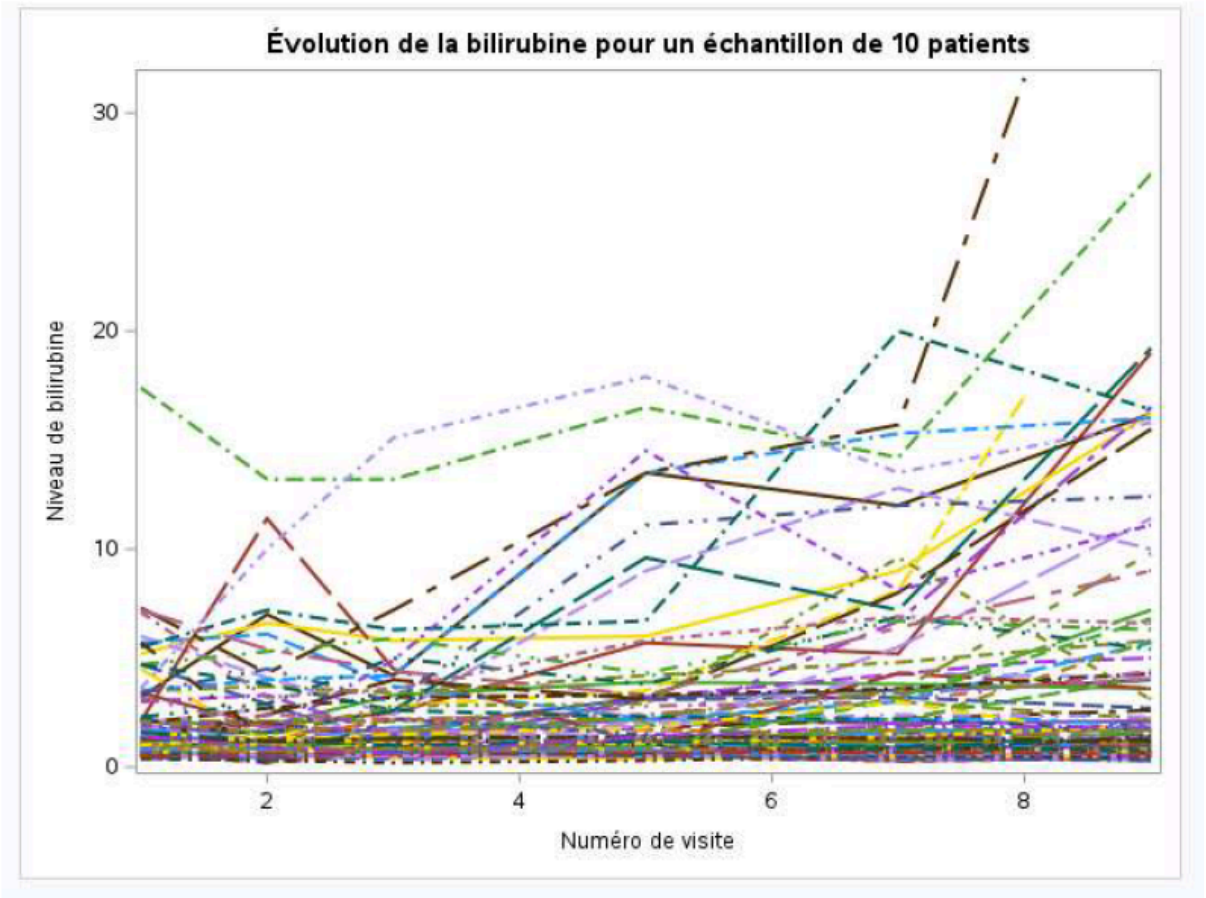

Calculer les moyennes et les intervalles de confiance

```
proc means data=cc.q4 noprint;
class Groupe_ttt Vis; * Groupement par groupe de traitement
et visite ;
var Plaquettes; * Variable d'intérêt ;
output out=mean_data mean=Mean_Plaquettes std=Std_Plaquette
s n=N; * Calcul de la moyenne et de l'écart-type ;
run;
```

Calculer l'intervalle de confiance à 95%

```
data mean_data;
set mean_data;
Lower_CI = Mean_Plaquettes - 1.96 * (Std_Plaquettes / sqrt
(N));
Upper_CI = Mean_Plaquettes + 1.96 * (Std_Plaquettes / sqrt
```

```
(N));
run;
```

Tracer les résultats
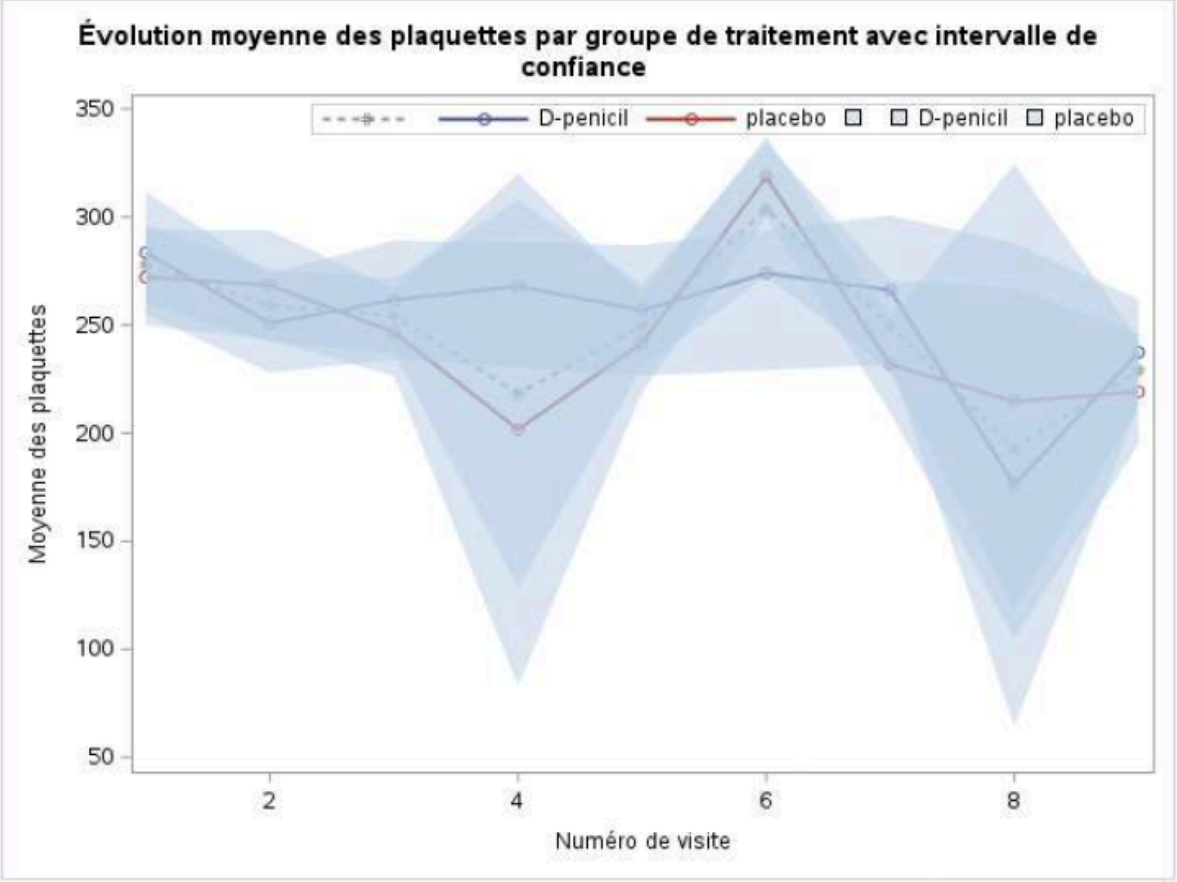
```
proc sgplot data=mean_data;
series x=Vis y=Mean_Plaquettes / group=Groupe_ttt markers l
ineattrs=(thickness=2);
band x=Vis lower=Lower_CI upper=Upper_CI / group=Groupe_ttt
fillattrs=(transparency=0.5);
xaxis label="Numéro de visite";
yaxis label="Moyenne des plaquettes";
keylegend / location=inside position=topright;
title "Évolution moyenne des plaquettes par groupe de trait
ement avec intervalle de confiance";
run;
```